

智能体搭建系统设计需求说明书

基于会议核心纪要与 PPT 辅助生成智能体架构演进规划

文档类型：需求规格及技术实现规范

当前时间：2026年7月

一、核心定位与业务演进变革

在本次会议中，团队针对智能体（Agent）系统的核心链路 with 业务定位进行了深刻反思与重构。摒弃了市场常规同质化的“大纲驱动”模式，确立了以高保真、高质量 Image2To 图像/视觉及多模态核心交互为主导的技术路线。

1. 摆脱同质化，打出市场差异化

- 传统方案普遍依赖先生成大纲、再逐步填充出稿的线性流水。团队决定在底层打破这一局限，“**直接砍掉大纲生成这一冗余节点**”，缩短前置路径，规避信息在多层级传递中的衰减与折损。
- 系统核心聚焦点转移至Image2To的高质量渲染、高适配视觉产出上，确保智能体输出的成果具备极高视觉冲击力与生产环境可用性。

2. 信息流无损传递与多轮唤醒

- 传统一轮流交互常常由于用户 prompt 简单而导致生成效果崩塌。新系统将通过 Agent 智能体建立**主动追问机制**，在感知到关键参数缺失时，启动多轮策略化引导，确保大模型深度理解用户真正意图。

二、核心功能模块与技术架构指标

1. 交互层：多轮引导式 AI 助手 (Agent Prompting Specialist)

该模块作为前端直接面向用户的智能交互中枢，需具备极高的话术策略与状态机维护能力：

- 前置输入解析**：无论用户输入的是碎片化自然语言、专业设计约束，还是长达数千字的超长提示词（系统需原生支持并深度解析 **5000字以上的复杂 Prompt 空间**），AI 助手均能精准提取意图。
- 10要素合规校验**：智能体内部预设 **10个核心画像与设计锚点**（如：目标受众、页面数量、设计风格、主色调、排版密度、功能组件、受众痛点等）。
- 反思与智能追问**：若检测到上述 10要素未完全在用户初始文本中体现，AI 助手将**禁止直接调用生成核心**，而是转入主动反思序列，以自然的上下文交互向用户连环追问，直至10要素补全。
- 出稿无损流**：要素齐备后，直接一键交付生成，摒弃任何中间过渡状态，提升响应体感。

2. 核心编排层：高阶 Agent 功能节点 (Hi-Agent Configuration)

系统后端基于主流的高阶 Agent 架构（如 Dify、火山引擎、Hi-Agent 等拓扑编排平台）进行快速对齐与原生能力扩展：

编排核心领域	系统搭建要求与技术规范
高级提示词配置	定义多模态智能体角色、前置目标与边界。设定极其严格的负向提示词，限制模型幻觉。
长期记忆空间 (Memory)	构建基于 Session ID 的上下文记忆，支持多轮交互信息不丢失；引入向量知识库作为智能体外置长期记忆。
插件与工具调用 (Tools)	预留标准 OpenAPI 接口，无缝融合 Image2To 高阶图像生成器、图表渲染引擎及第三方设计资产库。
工作流与触发器 (Workflow)	采用图形化拓扑节点，支持条件分支判别。允许根据用户选择，在初稿、设计稿、高保真稿之间智能流转。
外置知识库注入	支持企业级 PPT 模板库、历史优秀高标稿件、规范化行业提示词词典的一键挂载与向量检索。

3. 模型矩阵支持层 (LLM Pool)

系统采用混合云及混合模型架构，全面打通国内外最顶级的基础大模型能力：

- **DeepSeek 系列：** 核心接入 **DeepSeek V4-Flash 及 V4-Pro**。利用其强大的逻辑推理与极高的性价比，专门处理前端多轮追问、反思策略以及5000字提示词的语义压缩。
- **字节跳动火山引擎 (豆包/GLM)：** 深度接入字节跳动生态下的 **GLM-5 / 豆包大模型** 矩阵。主要依托其强大的中文原法语义理解及极速的高并发吞吐能力。

三、商业化变现与精细化计费系统 (Billing System)

为确保项目具备造血能力，必须同步推进商业化能力的建设，搭建多维度的商业计费底座：

1. 商业化闭环

系统必须原生集成标准微信支付、支付宝等第三方实时交易流水线，实现完全闭环的 **To C 个人用户直接变现能力**。

2. 精细化计费模式

由于后台调用了多模态图像生成与多大模型混合路由，算力成本高昂，系统必须摒弃粗放式计费，采用精细的**两级计费模型**：

 **算力计费矩阵：**

- 按页面/单次生成计费：** 用户可单次购买额度，例如“生成10页高保真PPT”或“生成20张高保真设计图”对应不同扣费标准。
- 按 Token 消耗计费：** 针对 5000 字以上超长提示词对话及高频多轮追问场景，直接透传后台 Token 计费阶梯，保障极端复杂任务下的边际利润。

四、进阶优化：单页高频深度微调架构 (Single-Page Iteration)

系统不仅需要具备单次全量生成能力，更需应对实际生产中频繁的**局部修改（改稿）**需求：

- **单页对话框常驻**：整个生成画布中，智能体需在每一页设计稿下方**常驻独立的局部对话微调框**。
- **上下文状态隔离**：用户在第3页微调框输入“把左上角的Logo颜色调淡，字号改小”时，智能体能够精准捕捉该页面的 DOM/图层状态，**实现单页局部精确迭代**，绝不影响其他已经生成的页面，彻底解决“牵一发而动全身”的系统顽疾。